

Aprendizado de Máquina

Introdução

Prof. Tiago A. Almeida

Motivação

- Escrever um programa de computador que:

- Reconheça pessoas pelo rosto

- Problemas:

- Diferentes expressões faciais
 - Alterações na face (ex. óculos, bigode)
 - Cortes de cabelo
 - Etc.



Que características considerar??

Seres humanos: reconhecimento de padrões, aprendizado do que deve ser observado após vários exemplos

Motivação

- Escrever um programa de computador que:

- Faça diagnóstico de pacientes por sintomas e exames

- Médico: formação e experiência



- Responda a questões sobre vendas como:

- Quais produtos são vendidos em conjunto?
 - Que produto recomendar a um cliente?
 - Como agrupar clientes para melhor marketing?



Inteligência Artificial e AM

- IA era vista como área teórica

- Aplicações em problemas de pouco valor prático

- 1970: disseminação maior em problemas reais

- Sistemas Especialistas / baseados em conhecimento
 - Conhecimento de especialista codificado
 - Frequentemente por regras lógicas

Como codificar subjetividade/intuição de especialista?
E como lidar com falta de cooperação?

Inteligência Artificial e AM

- Necessidade de ferramentas mais **autônomas**
 - Reduzindo necessidade de intervenção humana e dependência de especialistas

Aprendizado de Máquina: técnicas capazes de criar, a partir de experiência passada, uma hipótese (função) capaz de resolver o problema

- Ex: **Se** temperatura > 37° C **e** tem dores **então** está doente
 - Regra definida a partir de prontuários médicos



Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s


- 1952: programa jogador de **damas** de Samuel
- 1959: modelo **Pandemonium** de Selfridge
 - Reconhecimento de padrões
 - Padrão é reconhecido em partes antes do total
 - Aprendizado por meio de ajustes de pesos



Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s


- **Redes Neurais:** Perceptron (1957), Adaline (1960)
- 1969: Minsky e Papert provam limitações do Perceptron



Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s


- Indução simbólica de conceitos
- Sistemas especialistas
- Algoritmo ID3 (*Iterative Dichotomiser 3*) de Quinlan



Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Aprendizado de Regras
- Ressurgimento das Redes Neurais (*backpropagation* - 1986)
- Teoria de Aprendizado PAC (*Probably Approximately Correct*)
 - Estrutura para análise matemática de AM
- Foco em metodologia de experimentos



Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Sistemas Inteligentes Híbridos
- Mineração de Dados (1996) e de Textos
- Agentes de software adaptativos e aplicações na web
- Aprendizado por Reforço
- ILP (*Inductive Logic Programming*)
- *Ensembles: Bagging, Boosting e Stacking*
- Aprendizado por redes bayesianas
- Computação Bioinspirada



Histórico de AM

1950s > 1960s > 1970s > 1980s > 1990s > 2000s

- Máquinas de Vetores de Suporte (*Support Vector Machines*)
- Aplicações em:
 - Sistemas de Computadores
 - Engenharia de Software
 - Segurança (detecção de intrusão, vírus e worm)
 - Mineração da Web
 - Gerenciamento de E-mail
 - Bioinformática
 - PDAs que aprendem
 - Fluxo contínuo de dados



O que é aprendizado?

- Essencial para comportamento inteligente
- Algumas atividades:
 - Memorizar algo
 - Observar e explorar situações para aprender fatos
 - Melhorar habilidades motoras/cognitivas por prática
 - Organizar conhecimento novo em representações apropriadas



Aprendizado de Máquina: definição


Um programa **aprende** a partir da experiência **E**, em relação a uma classe de tarefas **T**, com medida de desempenho **P**, se seu desempenho em **T**, medido por **P**, melhora com **E**

– Mitchell, 1997

Algoritmos de AM: induzem uma função ou hipótese capaz de resolver o problema a partir de instâncias do problema a ser resolvido


Exemplo 1

- **Problema:** aprender a **jogar** damas
- **Tarefa T:** jogar damas
- **Medida de desempenho P:** ?
- **Experiência E:** ?



Exemplo 1

- **Problema:** aprender a **jogar** damas
- **Tarefa T:** jogar damas
- **Medida de desempenho P:** porcentagem de jogos vencidos contra adversários
- **Experiência E:** praticar jogando



Exemplo 2

- **Problema:** **filtrar** mensagens de email
- **Tarefa T:** categorizar mensagens de *email* como *spam* ou legítima
- **Medida de desempenho P:** ?
- **Experiência E:** ?



Exemplo 2

- **Problema:** **filtrar** mensagens de email
 - **Tarefa T:** categorizar mensagens de *email* como *spam* ou legítima
 - **Medida de desempenho P:** porcentagem de mensagens de *spam* corretamente identificadas
 - **Experiência E:** conjunto de exemplos de *spams*



Exemplo 3

- **Problema:** **reconhecer** escrita manual
 - **Tarefa T:** reconhecer e classificar dígitos manuscritos dentro de imagens
 - **Medida de desempenho P:** ?
 - **Experiência E:** ?

7210414959
0690159784
9665407401
3134727121
1742351244


Exemplo 3

- **Problema:** **reconhecer** escrita manual
 - **Tarefa T:** reconhecer e classificar dígitos manuscritos dentro de imagens
 - **Medida de desempenho P:** porcentagem de dígitos corretamente identificados
 - **Experiência E:** exemplos de dígitos manuscritos com as respectivas classificações

7210414959
0690159784
9665407401
3134727121
1742351244


Exemplo 4

- **Problema:** carro autônomo (aprender a **dirigir**)
 - **Tarefa T:** dirigir em uma rodovia pública usando sensores de visão
 - **Medida de desempenho P:** ?
 - **Experiência E:** ?



Exemplo 4

- **Problema:** carro autônomo (aprender a **dirigir**)
 - **Tarefa T:** dirigir em uma rodovia pública usando sensores de visão
 - **Medida de desempenho P:** distância média percorrida antes de um erro
 - **Experiência E:** sequência de imagens e comandos de direção registrados observando um motorista humano



Exemplo 5

- **Problema:** **diagnóstico** médico
 - **Tarefa T:** diagnosticar o estado de um paciente dado um conjunto de sintomas
 - **Medida de desempenho P:** ?
 - **Experiência E:** ?



Exemplo 5

- **Problema:** **diagnóstico** médico
 - **Tarefa T:** diagnosticar o estado de um paciente dado um conjunto de sintomas
 - **Medida de desempenho P:** porcentagem de pacientes corretamente diagnosticados
 - **Experiência E:** prontuários médicos de pacientes com seus diagnósticos



Exemplo 6

- **Problema:** **detectar** bons clientes
 - **Tarefa T:** classificar potenciais clientes como bons ou maus pagadores
 - **Medida de desempenho P:** ?
 - **Experiência E:** ?



Exemplo 6

- **Problema:** detectar bons clientes
 - **Tarefa T:** classificar potenciais clientes como bons ou maus pagadores
 - **Medida de desempenho P:** porcentagem de clientes classificados corretamente
 - **Experiência E:** uma base de dados histórica em que os clientes já conhecidos são previamente classificados como bons ou maus pagadores



Inferência Indutiva

- A **Inferência Indutiva** é um dos principais meios para a aquisição de novos conhecimentos
- **Indução:** raciocínio para obter conclusões sobre todos os membros de uma classe pelo exame de alguns membros da classe

Inferência indutiva: exemplo

- Se eu noto que:
 - Todos pacientes com déficit de atenção atendidos em 1986 sofriam de ansiedade
 - Todos pacientes com déficit de atenção atendidos em 1987 sofriam de ansiedade
 - ...
- **⇒ Posso inferir que pacientes que sofrem de déficit de atenção também sofrem de ansiedade**

Isto pode ser ou não verdade,
mas propicia uma boa generalização

Conjunto de dados

- Experiência pode ser provida por um conjunto de dados (de treinamento)
 - Ex. base de dados de um hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Conjunto de dados

Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Meta: induzir hipótese para fazer diagnósticos corretos para novos pacientes

Conjunto de dados

Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Cada **linha** (paciente) é um **dado**
(amostra, objeto, exemplo, padrão ou registro)

Conjunto de dados

Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Cada objeto é uma tupla com valores de **características** (atributos, campos ou variáveis), que descrevem seus principais aspectos

Conjunto de dados

Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Atributo de saída (alvo/meta): presente em algumas tarefas, seus valores devem ser estimados usando outros atributos (de entrada/preditivos)

Importante: atributos de identificação e nome não possuem relação com a doença e não são utilizados como entradas

Conjunto de dados

Hospital

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38	2	SP	Doente
3217	Maria	18	F	19	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38	2	RS	Saudável
1920	José	128	M	43	Inexistentes	38,5	62	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38	3	RJ	Doente
1322	Marta	19	F	-	Espalhadas	49	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Importante: lidar com dados imperfeitos (ruídos, ausentes, etc.)

AM: multidisciplinar

Probabilidade e Estatística

Teoria da Informação

Aprendizado de Máquina

Teoria da Computação

Neurociência

...

Tarefas de Aprendizado

Preditivas vs Descritivas

Previsão

Encontrar função (modelo ou hipótese) que possa ser utilizada para prever um rótulo ou valor para novos dados

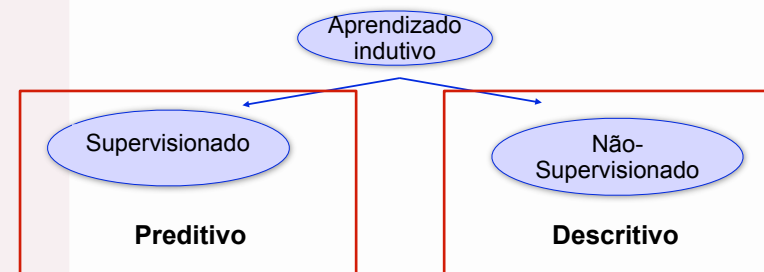
Objetos na forma (entrada, saída)

Descrição

Explorar ou descrever um conjunto de dados

Objetos não possuem saída associada

Hierarquia de aprendizado



Importante: divisão não é rígida (modelo preditivo também provê descrição dos dados e modelo descritivo pode prover previsões após validado)

Aprendizado supervisionado

- Supervisor externo
 - Conhece saída desejada para cada exemplo
 - Representado por conjunto de pares (x, y)
 - Ex.: x = sintomas e y = diagnóstico

Classificação

Rótulos discretos

Ex.: diagnóstico, bom/mau pagador, etc.

Regressão

Rótulos contínuos

Ex.: peso, altura, etc.

Aprendizado não supervisionado

- Algoritmos não fazem uso de atributo de saída
 - Exploram regularidades nos dados

Sumarização

Encontrar descrição compacta para dados

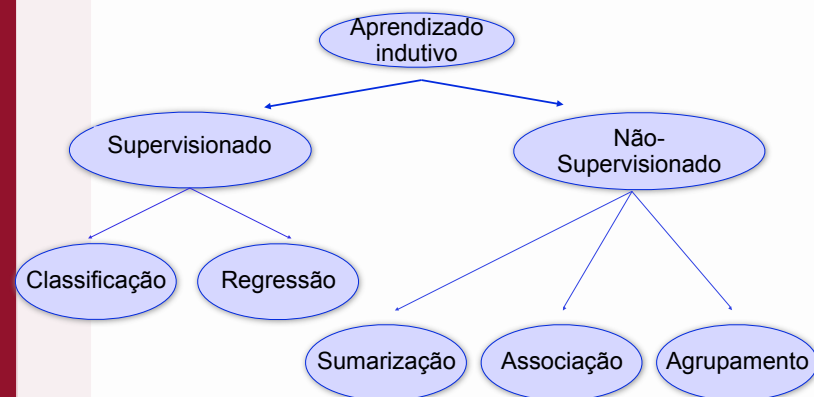
Associação

Encontrar padrões frequentes de associações entre atributos

Agrupamento

Dados agrupados de acordo com sua similaridade

Hierarquia de aprendizado



Aprendizado por reforço

- Reforçar/recompensar ações positivas e punir ações negativas
 - Crítico externo

Aprendizado supervisionado

- Supervisor
- É dito o que fazer
- Mais rápido

Aprendizado por reforço

- Crítico
- Faz e vê o que acontece
- Mais lento

Generalização

- Capacidade de **generalização** de uma hipótese:
 - Propriedade de continuar válida para outros objetos que não fazem parte de seu conjunto de treinamento

Problemas:

Overfitting: especialização nos dados de treinamento, não generaliza

Underfitting: baixo acerto mesmo nos dados de treinamento


Viés indutivo

- Aprendizado:** busca de hipótese em espaço de possíveis hipóteses
 - Que descreva relacionamentos entre os dados
 - E se ajuste aos dados de treinamento
- Todo algoritmo de AM indutivo tem um viés
 - Na escolha de uma hipótese (ou conjunto)

Sem viés, não haveria generalização (modelos seriam especializados para os exemplos individuais)

Viés indutivo

- Viés de **representação ou linguagem**
 - Define o espaço de busca
 - Restringe hipóteses que podem ser geradas



Viés indutivo

- Viés de **preferência ou busca**
 - Como hipóteses são pesquisadas
 - Preferência de algumas hipóteses sobre outras
 - Ex.: preferência por hipóteses curtas
 - Navalha de Occam

"Se em tudo o mais forem idênticas as várias explicações de um fenômeno, a mais simples é a melhor"

AM: outras motivações

- Automatizar o processo de aquisição de conhecimento
- Entender melhor os mecanismos de aprendizado humano
- Algumas tarefas são melhor definidas e/ou executadas a partir de exemplos
 - Ex.: Reconhecer pessoas
- Ser humano não é capaz de explicar (e programar) sua habilidade para executar alguns tipos de tarefas
 - Ex.: Dirigir



AM: outras motivações

- Quantidade de conhecimento disponível pode ser muito grande para ser descrito (e programado) por humanos
 - Ex.: diagnóstico médico
- Algumas tarefas exigem cálculos complexos, possíveis apenas com computador
 - Ex.: interrelacionar/correlacionar grandes quantidades de dados
- Modelos podem se adaptar a novas situações



Pacotes e conjuntos de dados

- UCI Machine Learning repository
 - <http://archive.ics.uci.edu/ml/>
- Weka
 - <http://www.cs.waikato.ac.nz/ml/weka/>
- Keel
 - <http://www.keel.es/>
- R Project
 - <http://www.r-project.org/>

Referências

- Capítulo 1 do livro Inteligência Artificial: uma abordagem de Aprendizado de Máquina, 2011
- Alguns slides foram baseados em apresentações de:
 - Prof Dr André C. P. L. F. Carvalho
 - Prof Ricardo Campello
 - Profa Solange O. Rezende
 - Prof Dr Marcilio C. P. Souto