

Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Regressão

Prof. Tiago A. Almeida

Modelos preditivos

- **Definição formal:** dado conjunto de observações
- $D = \{(\mathbf{x}^{(i)}, f(\mathbf{x}^{(i)})), i = 1, \dots, m\}$
 - f representa uma função desconhecida: **função objetivo**
 - Mapeia entradas em saídas correspondentes
 - Algoritmo preditivo aprende **aproximação** \hat{f}
 - Que permite estimar valor de f para novos objetos \mathbf{x}

Regressão

$$y^{(i)} = f(\mathbf{x}^{(i)}) \in \Re$$

Regressão

- Ilustração das tarefa:



Regressão

- **Regressão:**
 - **Meta:** aprender função (curva aproximada) que relacione entradas a valores contínuos de saídas
- Exemplos:
 - Prever valor de mercado de um imóvel
 - Prever o lucro de um empréstimo bancário

Regressão: Modelo

conjunto de dados

x_{11}	x_{12}	...	x_{1n}	y_1
x_{21}	x_{22}	...	x_{2n}	y_2
\vdots	\vdots		\vdots	\vdots
x_{m1}	x_{m2}	...	x_{mn}	y_m

Técnica de
regressão

h
Hipótese

Treinamento

Objetivo: preditor capaz de prever corretamente o valor de novos dados

\mathbf{x} x_1 x_2 ... x_n
novo dado



h
Preditor



$h(\mathbf{x})$
previsão
Teste

Regressão

- Técnicas de AM:
 - Regressão Linear
 - Árvores de Regressão
 - Redes Neurais Artificiais
 - Máquinas de Vetores de Suporte
 - Etc.


Cada técnica de AM utiliza um mecanismo distinto na aproximação da função objetivo

Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Regressão Linear com uma Variável

Regressão: exemplo

- Conjunto de treinamento (valor de imóveis)



Regressão: exemplo

- Conjunto de treinamento (valor de imóveis)


Tamanho (x)	Valor x US\$ 1000 (y)
2104	460
1416	232
1534	315
852	178
...	...

Notação

m = número de amostras
 x = atributos (entrada)
 y = meta (saída)


Representação da hipótese (h)

- Hipótese:



Representação da hipótese (h)


- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$



- Regressão linear com uma variável
- Regressão linear univariada

Representação da hipótese (h)

- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$



- Regressão linear com uma variável
- Regressão linear univariada

Escolha da hipótese

- Conjunto de treinamento (valor de imóveis)

Tamanho (x)	Valor x U\$ 1000 (y)
2104	460
1416	232
1534	315
852	178
...	...


Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$

Parâmetros: θ_i

Como escolher bons valores para θ_i ?


Escolha de θ

- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$




Escolha de θ

- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$




Escolha de θ

- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$




Escolha de θ

- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$



Escolha de θ


- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$



Objetivo: encontrar θ_0, θ_1 de tal forma que $h(\mathbf{x})$ aproxima \mathbf{y} para os exemplos de treinamento.

Escolha de θ

- Hipótese: $h_{\theta}(x) = \theta_0 + \theta_1(x)$




Em outras palavras:
- Escolher θ_0, θ_1 que minimize o **Erro Quadrático Médio** entre as previsões ($h(\mathbf{x})$) e as saídas esperadas (\mathbf{y}) para as amostras de treinamento.

Objetivo: encontrar θ_0, θ_1 de tal forma que $h(\mathbf{x})$ aproxima \mathbf{y} para os exemplos de treinamento.

Função Custo (J)

- Erro quadrático médio


$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$$



Função Custo (J)

- Minimizar o erro:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$$



$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$$

Objetivo: encontrar θ_0, θ_1 de tal forma que $h(\mathbf{x})$ aproxima \mathbf{y} para os exemplos de treinamento.

Função Custo (J): Interpretação

- Hipótese:**
 $h_{\theta}(x) = \theta_0 + \theta_1(x)$
- Parâmetros:**
 θ_0, θ_1
- Função Custo:**
 $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$
- Objetivo:**
 $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Função Custo (J): Interpretação

- Hipótese:**
 $h_{\theta}(x) = \theta_0 + \theta_1(x)$

- Parâmetros:**
 θ_0, θ_1

- Função Custo:**
 $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$

- Objetivo:**
 $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Vamos supor que:


$$h_{\theta}(x) = \theta_1 x$$

$$\theta_1$$


$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\min_{\theta_1} J(\theta_1)$$


Função Custo (J): Interpretação



Função Custo (J): Interpretação




Função Custo (J): Interpretação



Função Custo (J): Interpretação


Variando θ_1 obtém-se uma parábola para $J(\theta_1)$



Função Custo (J): Interpretação


Variando θ_1 obtém-se uma parábola para $J(\theta_1)$

Como deseja-se obter θ_1 que minimize $J(\theta_1)$, então $\theta_1 = 1$ é a melhor escolha para esse exemplo, pois $J(1) = 0$




Função Custo (J): Interpretação

- Conjunto de treinamento (valor de imóveis)

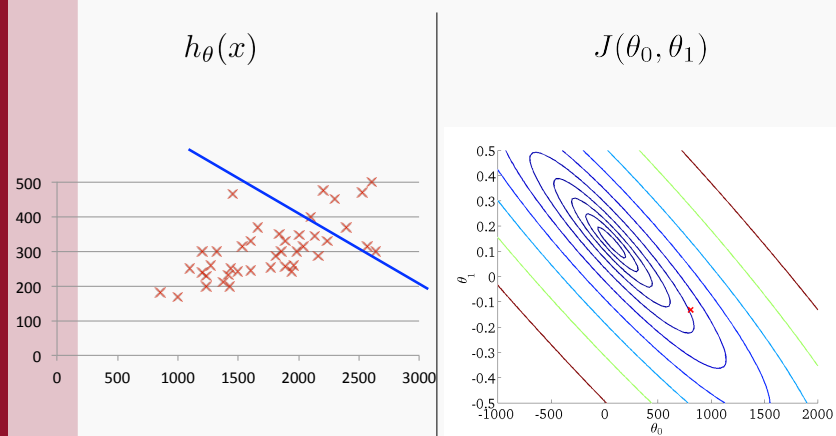


Função Custo (J): Interpretação

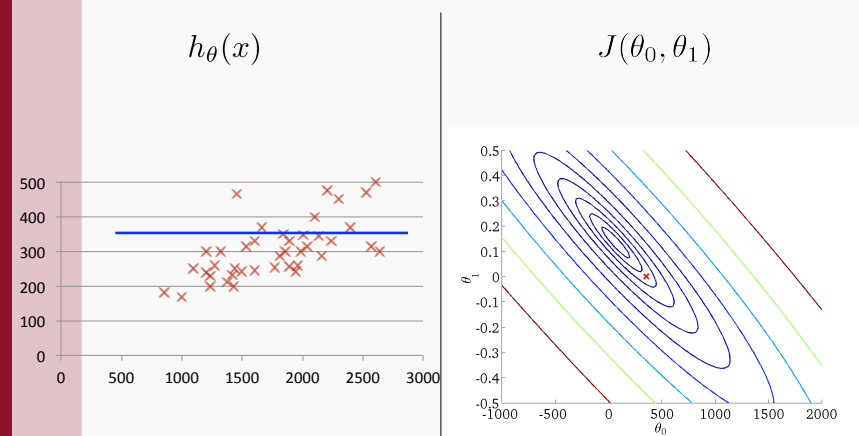
- $J(\theta_0, \theta_1)$



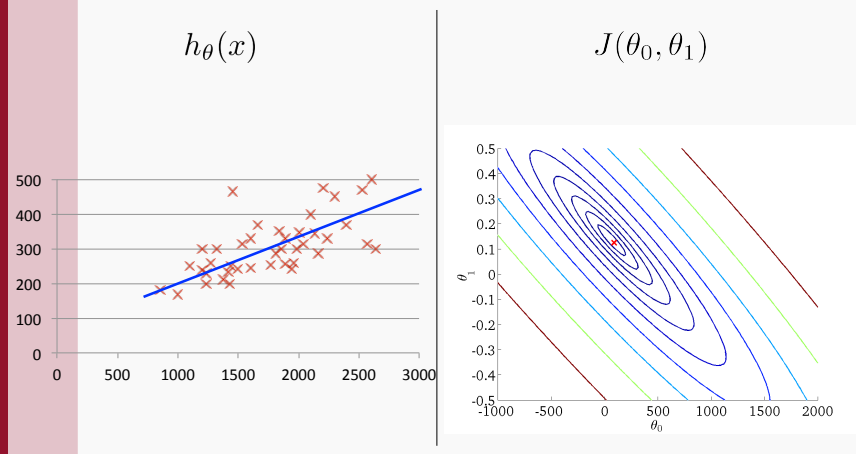
Função Custo (J): Interpretação



Função Custo (J): Interpretação




Função Custo (J): Interpretação




Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Gradiente Descendente


Gradiente descendente




Gradiente descendente




Gradiente descendente




Gradiente descendente



Gradiente descendente



Gradiente descendente



Gradiente descendente

Repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{para } j = 0 \text{ e } j = 1)$$

}

A atualização dos θ_j deve ser "simultânea"

Gradiente descendente

Repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{para } j = 0 \text{ e } j = 1)$$

}

Taxa de
aprendizagem

Derivada
parcial

Gradiente descendente

Repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{para } j = 0 \text{ e } j = 1)$$

}

Taxa de
aprendizagem

- Se α for muito pequeno, a convergência poderá ser lenta;
- Se α for muito grande, poderá não haver convergência.

Gradiente descendente

Repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{para } j = 0 \text{ e } j = 1)$$

}

- O método converge para um ótimo local mesmo se α for um valor fixo
- Conforme o ótimo for se aproximando, o método reduz o tamanho do passo automaticamente

Gradiente descendente para regressão linear

Repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{para } j = 0 \text{ e } j = 1)$$

}

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$$

↓

$$h_{\theta}(x) = \theta_0 + \theta_1(x)$$

Gradiente descendente para regressão linear

Repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{para } j = 0 \text{ e } j = 1)$$

}

$$j = 0 : \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)$$

$$j = 1 : \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x^i$$

Gradiente descendente para regressão linear

Algoritmo:

repetir até convergir {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x^i$$

}

Atualizar "simultaneamente" θ_0 e θ_1

Gradiente descendente para regressão linear


■ Observações importantes

- GD é sensível à escala dos dados
 - É recomendável aplicar normalização por padronização para fazer com que $-1 \leq x_i \leq 1$

Gradiente descendente para regressão linear

Observações importantes

- GD é sensível à escala dos dados
 - É recomendável aplicar normalização por padronização para fazer com que $-1 \leq x_i \leq 1$
- GD é sensível à taxa de aprendizagem
 - Recomendável testar α com ..., 0.001, 0.01, 0.1, 1, ...
 - Certifique-se de que $J(\theta)$ **decrece** a cada iteração. Caso contrário, reduza o valor de α



Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina

Regressão Linear com Múltiplas Variáveis

Regressão linear com múltiplas variáveis

Tamanho	#Cômodos	#Andares	#Anos	Valor (U\$1000)
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...

Notação:

n = quantidade de atributos

$x^{(i)}$ = i^{th} amostra do conjunto de treinamento

$x_j^{(i)}$ = valor do atributo j da i^{th} amostra do conjunto de treinamento

Regressão linear com múltiplas variáveis

Regressão linear univariada

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

Regressão linear com múltiplas variáveis

- Regressão linear univariada

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

- Regressão linear multivariada

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

Regressão linear com múltiplas variáveis

- Regressão linear univariada

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

- Regressão linear multivariada

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

Para simplificar: $x_0 = 1$

Regressão linear com múltiplas variáveis

- Regressão linear univariada

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

- Regressão linear multivariada

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

Para simplificar: $x_0 = 1$

$$h_{\theta}(x) = \theta^T x$$

Regressão linear com múltiplas variáveis

Hipótese: $h_{\theta}(x) = \theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$

Parâmetros: $\theta_0, \theta_1, \dots, \theta_n$

Função de custo:

$$J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Gradiente descendente

Repita {
 $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \dots, \theta_n)$
 }

Regressão linear com múltiplas variáveis

Algoritmo:

repetir até convergir {

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_j^i$$

}

Atualizar "simultaneamente" θ_j

Regressão linear com múltiplas variáveis

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_j^i$$



$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_0^i$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_1^i$$

$$\theta_2 := \theta_2 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_2^i$$

...